Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №4

По дисциплине «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей с использованием RBM»

Выполнил:

Студент 4 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью RBM.

Задание: взять за основу нейронную сеть из лабораторной работы №3. Выполнить обучение с предобучением, используя стек ограниченных машин Больцмана (RBM – Restricted Boltzmann Machine), алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев как RBM выбрать самостоятельно. Сравнить результаты, полученные при обучении без предобучения (ЛР 3); обучении с предобучением, используя автоэнкодерный подход (ЛР3); обучении с предобучением, используя RBM. Обучить модели на данных из ЛР 2, сравнить результаты по схеме из пункта 2; Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 2

Датасет: https://archive.ics.uci.edu/dataset/189/parkinsons+telemonitoring, **тип задачи:** регрессия, **целевая переменная:** motor_UPDRS

Ход работы

Результат:

```
Устройство: cuda
Сиды: [42, 1, 2, 5, 7]

PARKINSONS (регрессия motor_UPDRS, данные ЛР3)
seed = 42
  Предобучение RBM:
    RBM 19-64: recon MSE = 0.3764
    RBM 64-32: recon MSE = 0.0144
    RBM 32-16: recon MSE = 0.0064
...
PARKINSONS (среднее ± std по 5 сидам)
Метод                     MAPE              RMSE              R2
Без предобучения   0.6912±0.2270    11.5645±1.9706   -1.0712±0.4586
Предобучение AE    0.7345±0.2549    12.0986±1.9161   -1.3211±0.7726
Предобучение RBM   0.7173±0.2473    11.5028±1.6936   -1.1549±0.8639

MUSHROOM (классификация poisonous, данные ЛР2)
Метод                     F1                Accuracy
Без предобучения   1.0000±0.0000    1.0000±0.0000
Предобучение AE    1.0000±0.0000    1.0000±0.0000
Предобучение RBM   1.0000±0.0000    1.0000±0.0000
```

PyTorch, CUDA, seed = 42. Adam, lr = 0.001, batch = 128, перемешивание каждую эпоху, активация ReLU. Parkinsons разбивается через GroupShuffleSplit по subject# (33 пациента в train, 9 в test) – разбиение перенесено из ЛР3, поскольку при обычном train_test_split все 42 пациента были и в train, и в test, что давало утечку и завышенные метрики. Признаки и целевая переменная стандартизуются StandardScaler только по train. Для всех трёх вариантов

одинаковые архитектура, оптимизатор, разбиение и процедура дообучения; все результаты – в одном запуске.

В датасете Parkinsons всего 42 уникальных пациента (subject# 1–42) и ~5 875 записей, то есть ~140 измерений на пациента. Поэтому при GroupShuffleSplit в тест попадает 9 пациентов, хотя тестовая выборка содержит ~1 175 строк. Это свойство датасета, а не ошибка разбиения.

Архитектура. Полносвязная сеть из ЛР3 (4 линейных слоя): Parkinsons – 19–64–32–16–1; Mushroom – 117–64–32–16–2 (после One-Hot, как в ЛР2).

Алгоритм предобучения RBM. Послойный (greedy layer-wise). Первая RBM n–64 обучается на данных; скрытые вероятности $P(y=1|x)$ подаются на вход второй RBM 64–32, затем третьей 32–16. Веса переносятся в сеть: W^T в веса Linear, T_j в смещения; выходной слой – случайная инициализация. Затем обучается только выходной слой (20 эпох; MSE для регрессии, CrossEntropy для классификации), после чего – дообучение всей сети обратным распространением (300 эпох).

Обучение одной RBM – CD-1: для каждого мини-батча вычисляется $P(y^{(0)}=1|x^{(0)}) = \mathrm{sigm}(\Sigma_i\, w_{ij}\, x_i^{(0)} + T_j)$ и генерируется $y^{(0)} \in \{0,1\}$; вычисляется реконструкция $x^{(1)}$ по $y^{(0)}$; вычисляется $P(y^{(1)}=1|x^{(1)})$; обновление $W \leftarrow W + \alpha(x^{(0)}y^{(0)T} - x^{(1)}P(y^{(1)}=1|x^{(1)})^T)$, $T_i \leftarrow T_i + \alpha(x^{(0)} - x^{(1)})$, $T_j \leftarrow T_j + \alpha(y^{(0)} - P(y^{(1)}=1|x^{(1)}))$. Скрытые нейроны бинарные (сигмоида с выборкой). Видимые нейроны первой RBM линейные (гауссовы), так как стандартизованные входы не лежат в [0,1]; для второй и третьей RBM – сигмоидные с выборкой, поскольку их входы – вероятности из [0,1]. Для Mushroom (One-Hot уже в [0,1]) все RBM Bernoulli-Bernoulli.

Параметры и условие останова. 50 эпох на RBM, $\alpha = 0.01$, момент 0.5 (первые 5 эпох), затем 0.9, batch = 128, $W \sim N(0, 0.01^2)$, пороги нулевые. Число эпох выбрано самостоятельно.

Ошибка реконструкции RBM (MSE, последняя эпоха). Parkinsons: 19–64 – 0.3764, 64–32 – 0.0144, 32–16 – 0.0064. Mushroom: 117–64 – 0.0273, 64–32 – 0.0180, 32–16 – 0.0121. Ошибки ненулевые и небольшие.

Сравнение на Parkinsons (регрессия). 19 признаков, целевая motor_UPDRS; 33 пациента в train, 9 в test. Метрики: MAPE, RMSE, R^2. Для оценки стабильности – усреднение по 5 сидам (42, 1, 2, 5, 7), результат в виде среднее ± std.

Различия между методами по MAPE ≤ 0.04, по RMSE ≤ 0.6, по $R^2 \leq 0.25$ – меньше стандартного отклонения (0.23–0.25 по MAPE и 1.7–2.0 по RMSE). Статистически значимого преимущества какого-либо способа предобучения не выявлено. Формально лучший RMSE у RBM (11.5028), лучший MAPE – у сети без предобучения (0.6912), но отличия меньше std. Отрицательный R^2 во всех случаях означает, что модель предсказывает хуже тривиального baseline (среднее по train); это ожидаемо при 9 тестовых пациентах с индивидуальными профилями motor_UPDRS и согласуется с ЛР3 (там R^2 −0.3679 и −0.3555 при одном сиде).

Сравнение на Mushroom (классификация). 8 124 объекта, 22 категориальных признака, после One-Hot – 117 бинарных; 2 класса (poisonous – 3 916, edible – 4 208). Метрики: F1 (poisonous), Accuracy, матрица ошибок.

Все три подхода достигают F1 = 1.0 и Accuracy = 1.0 на всех сидах, матрица ошибок без ошибок. Задача Mushroom слишком проста для выявления преимущества предобучения: обычная полносвязная сеть с ReLU и Adam справляется без него. Сравнение иллюстрирует, что

предобучение (AE и RBM) не ухудшает результат на лёгких данных, но не позволяет судить о его пользе.

Общие выводы. Сравнение трёх способов выполнено на Parkinsons (регрессия, данные ЛР3) и Mushroom (классификация, данные ЛР2). На Parkinsons предобучение (AE и RBM) не дало подтверждённого преимущества: различия между методами в пределах стандартного отклонения по 5 сидам, что объясняется малой тестовой выборкой (9 пациентов) и большой межиндивидуальной вариативностью целевой переменной. На Mushroom все три подхода достигают потолка F1 = 1.0, поэтому сравнение неинформативно. Результаты согласуются с ЛР3 (там AE дал небольшое улучшение на одном сиде, но в пределах шума). Возможные причины отсутствия выигрыша: (1) веса RBM получены для сигмоидных нейронов, а в сети используется ReLU; (2) малая размерность входа Parkinsons (19 признаков) и небольшие размеры слоёв; (3) малый размер тестовой выборки Parkinsons (9 пациентов); (4) простота задачи Mushroom.

Вывод: научились осуществлять предобучение нейронных сетей с помощью RBM.