Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №5

По дисциплине «Интеллектуальный анализ данных»

Тема: «Деревья решений»

Выполнил:

Студент 4 курса

Группы ИИ-25

Бекназарова А. С.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: на практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задание: загрузить датасет по варианту. Разделить данные на обучающую и тестовую выборки. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost). Оценить точность каждой модели на тестовой выборке. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 2

Датасет: Breast Cancer Wisconsin, **задача:** определить, является ли опухоль злокачественной (malignant) или доброкачественной (benign).

Ход работы

Результат:

```
Удаляем полностью пустые колонки: ['Unnamed: 32']
Удаляем колонку id
Пропусков в данных нет.
Уникальные значения целевой переменной: ['B', 'M']
Целевая переменная преобразована: M -> 1, B -> 0

Размер обучающей выборки: (455, 30)
Размер тестовой выборки: (114, 30)

Обучение модели: Decision Tree
Время обучения: 0.01 сек
Accuracy: 0.9298
Матрица ошибок:
[[68  4]
 [ 4 38]]

Отчет по метрикам:
                      precision    recall  f1-score   support

Доброкачественная (0)       0.94      0.94      0.94        72
  Злокачественная (1)       0.90      0.90      0.90        42

             accuracy                           0.93       114
            macro avg       0.92      0.92      0.92       114
         weighted avg       0.93      0.93      0.93       114

Обучение модели: Random Forest
Время обучения: 0.23 сек
Accuracy: 0.9737
Матрица ошибок:
[[72  0]
 [ 3 39]]

Отчет по метрикам:
                      precision    recall  f1-score   support

Доброкачественная (0)       0.96      1.00      0.98        72
```

```
  Злокачественная (1)       1.00      0.93      0.96        42

            accuracy                           0.97       114
           macro avg       0.98      0.96      0.97       114
        weighted avg       0.97      0.97      0.97       114

Обучение модели: AdaBoost
Время обучения: 0.32 сек
Accuracy: 0.9737
Матрица ошибок:
[[72  0]
 [ 3 39]]

Отчет по метрикам:
                      precision    recall  f1-score   support

Доброкачественная (0)       0.96      1.00      0.98        72
  Злокачественная (1)       1.00      0.93      0.96        42

            accuracy                           0.97       114
           macro avg       0.98      0.96      0.97       114
        weighted avg       0.97      0.97      0.97       114

Обучение модели: XGBoost
Время обучения: 0.21 сек
Accuracy: 0.9649
Матрица ошибок:
[[72  0]
 [ 4 38]]

Отчет по метрикам:
                      precision    recall  f1-score   support

Доброкачественная (0)       0.95      1.00      0.97        72
  Злокачественная (1)       1.00      0.90      0.95        42

            accuracy                           0.96       114
           macro avg       0.97      0.95      0.96       114
        weighted avg       0.97      0.96      0.96       114

Обучение модели: CatBoost
Время обучения: 5.72 сек
Accuracy: 0.9649
Матрица ошибок:
[[72  0]
 [ 4 38]]

Отчет по метрикам:
                      precision    recall  f1-score   support

Доброкачественная (0)       0.95      1.00      0.97        72
  Злокачественная (1)       1.00      0.90      0.95        42

            accuracy                           0.96       114
           macro avg       0.97      0.95      0.96       114
        weighted avg       0.97      0.96      0.96       114
```

```
Сравнение моделей по Accuracy:
Random Forest: 0.9737
AdaBoost: 0.9737
XGBoost: 0.9649
CatBoost: 0.9649
Decision Tree: 0.9298

Лучшая модель по Accuracy: Random Forest (0.9737)

Анализ Recall для класса Злокачественная:
Decision Tree: Recall = 0.9048
Random Forest: Recall = 0.9286
AdaBoost: Recall = 0.9286
XGBoost: Recall = 0.9048
CatBoost: Recall = 0.9048
```

Данные разделены в пропорции 80/20 со стратификацией, чтобы в тестовой выборке сохранилась исходная доля злокачественных и доброкачественных опухолей.
Признаки стандартизированы с помощью StandardScaler.
Гиперпараметры моделей зафиксированы заранее (random_state=42), по тестовой выборке не подбирались.

Загружен набор Breast Cancer Wisconsin: 569 записей и 30 числовых признаков (радиус, текстура, периметр, площадь и другие характеристики ядра клетки). Целевая переменная – diagnosis, где M означает злокачественную опухоль, а B – доброкачественную.
При просмотре данных выяснилось, что в исходном CSV-файле есть пустая колонка Unnamed: 32 (она появилась из-за лишней запятой в конце строк). Она была удалена, так как не содержит никакой информации. Колонку id тоже была удалена – это просто номер записи, для классификации она бесполезна. После очистки пропусков в данных не осталось. Целевая переменная переведена в числовой вид: M → 1, B → 0.

Модель	Основные параметры
Дерево решений	random_state = 42
Случайный лес	100 деревьев, random_state = 42
AdaBoost	100 деревьев, random_state = 42
XGBoost	random_state = 42
CatBoost	random_state = 42, verbose = 0

Для каждой модели посчитаны точность (accuracy), матрица ошибок, а также precision, recall и F1-score для класса «злокачественная опухоль».

Модель	Время обучения	Accuracy	Precision (1)	Recall (1)	F1 (1)	Матрица ошибок

Дерево решений	0.01 с	0.9298	0.90	0.9048	0.90	TN=68, FP=4, FN=4, TP=38
Случайный лес	0.23 с	0.9737	1.00	0.9286	0.96	TN=72, FP=0, FN=3, TP=39
AdaBoost	0.32 с	0.9737	1.00	0.9286	0.96	TN=72, FP=0, FN=3, TP=39
XGBoost	0.21 с	0.9649	1.00	0.9048	0.95	TN=72, FP=0, FN=4, TP=38
CatBoost	5.72 с	0.9649	1.00	0.9048	0.95	TN=72, FP=0, FN=4, TP=38

Первое, что бросается в глаза: все ансамбли обошли одиночное дерево. Дерево решений показало точность 92.98%, а остальные модели – от 96.49% до 97.37%. Это классическая ситуация: одиночное дерево легко переобучается и сильнее реагирует на шум, тогда как ансамбли усредняют ошибки множества деревьев и работают стабильнее.

Лучшими по accuracy и recall оказались случайный лес и AdaBoost – у обоих точность 97.37% и recall 92.86%. При этом у них ноль ложноположительных срабатываний (ни одна доброкачественная опухоль не была названа злокачественной) и всего 3 ложноотрицательных.

XGBoost и CatBoost немного отстали: accuracy 96.49%, recall 90.48%, то есть по 4 ложноотрицательных. Разница в один пропущенный случай на 42 объекта – это в пределах статистической погрешности, но формально лес и AdaBoost сработали лучше.

Отдельно стоит отметить время обучения. CatBoost обучался 5.72 секунды, тогда как остальные модели уложились в 0.01–0.32 секунды. Это связано с тем, что CatBoost оптимизирован под большие данные с категориальными признаками, а здесь все признаки числовые и записей немного – его преимущества не раскрываются, остаются только накладные расходы.

Дерево решений – самое простое и понятное: правила можно показать врачу, и он увидит логику принятия решения. Но точность ниже, и модель нестабильна. Хороша как базовая интерпретируемая модель, но не как основной классификатор.

Случайный лес – показал лучшую точность вместе с AdaBoost и минимальное число ошибок. Быстро обучается (0.23 с), устойчив к шуму. Для этого датасета – оптимальный выбор.

AdaBoost – результаты на уровне случайного леса, но обучение чуть дольше (0.32 с). Хорошая альтернатива.

XGBoost и CatBoost – качественные модели, но на таком небольшом датасете (569 записей) их преимущества перед лесом не проявились. CatBoost к тому же заметно медленнее.

В задаче классификации опухолей пропустить злокачественное образование (ложноотрицательный прогноз) гораздо опаснее, чем ошибочно отправить здорового человека на дополнительное обследование (ложноположительный прогноз). Поэтому главная метрика здесь – recall для класса «злокачественная», а precision и accuracy важны, но вторичны.

Наиболее надёжными для минимизации ложноотрицательных прогнозов оказались случайный лес и AdaBoost: у них recall 92.86% и всего 3 пропущенных случая из 42. XGBoost и CatBoost

пропустили на один случай больше (recall 90.48%). Разница небольшая, но при равной точности и скорости выбор логично остановить на случайном лесе.
Тестовая выборка небольшая (114 объектов, из них 42 злокачественных), поэтому метрики имеют заметный разброс: один пропущенный пациент меняет recall примерно на 2.4%.
Гиперпараметры не подбирались – использованы фиксированные значения, чтобы сравнение было честным.

Вывод: на практике сравнили работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.