Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5
По дисциплине: «ИНТЕЛЛЕКТУАЛЬНЫЙ АНАЛИЗ ДАННЫХ»
Тема: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-25
Максимчук Е. А.
Проверил:
Андренко К. В.

Брест 2026

Цель работы: На практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задание:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 5

- `Mushroom Classification`
- Определить, является ли гриб ядовитым или съедобным
- **Задания:**
    1. Загрузите данные и преобразуйте все категориальные признаки в числовые (например, с помощью One-Hot Encoding);
    2. Разделите данные на обучающую и тестовую части;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Рассчитайте точность и полноту (precision и recall) для класса "ядовитый";
    5. Сделайте вывод о том, какой классификатор лучше всего справляется с этой задачей, где цена ошибки очень высока.

Результаты:

	name	role	...	units	missing_values
0	poisonous	Target	...	None	no
1	cap-shape	Feature	...	None	no
2	cap-surface	Feature	...	None	no
3	cap-color	Feature	...	None	no
4	bruises	Feature	...	None	no
5	odor	Feature	...	None	no
6	gill-attachment	Feature	...	None	no
7	gill-spacing	Feature	...	None	no
8	gill-size	Feature	...	None	no
9	gill-color	Feature	...	None	no
10	stalk-shape	Feature	...	None	no
11	stalk-root	Feature	...	None	yes
12	stalk-surface-above-ring	Feature	...	None	no
13	stalk-surface-below-ring	Feature	...	None	no
14	stalk-color-above-ring	Feature	...	None	no

15 stalk-color-below-ring Feature ... None no
16 veil-type Feature ... None no
17 veil-color Feature ... None no
18 ring-number Feature ... None no
19 ring-type Feature ... None no
20 spore-print-color Feature ... None no
21 population Feature ... None no
22 habitat Feature ... None no
[23 rows x 7 columns]
Данные: (8124, 22)
Ядовитые: 3916 (48.2%)
Съедобные: 4208
Обучающая: (6499, 117), тестовая: (1625, 117)
Ядовитых в тесте: 783, съедобных: 842
Метрики:

Модель	Accuracy	Precision (ядовитый)	Recall (ядовитый)
Decision Tree	1.000000	1.0	1.000000
Random Forest	1.000000	1.0	1.000000
XGBoost	1.000000	1.0	1.000000
CatBoost	1.000000	1.0	1.000000
AdaBoost	0.998769	1.0	0.997446

Матрицы ошибок [[TN, FP], [FN, TP]] (TN — съедобные верно, TP — ядовитые верно):
Decision Tree TN= 842 FP= 0 FN= 0 TP= 783
Random Forest TN= 842 FP= 0 FN= 0 TP= 783
AdaBoost TN= 842 FP= 0 FN= 2 TP= 781
XGBoost TN= 842 FP= 0 FN= 0 TP= 783
CatBoost TN= 842 FP= 0 FN= 0 TP= 783
Подробный отчёт по классам для лучшей по Recall модели:
Лучшая по Recall: Decision Tree

	precision	recall	f1-score	support
съедобный (0)	1.00	1.00	1.00	842
ядовитый (1)	1.00	1.00	1.00	783
accuracy			1.00	1625
macro avg	1.00	1.00	1.00	1625
weighted avg	1.00	1.00	1.00	1625

Общие наблюдения

Результаты одного разбиения для задачи с высокой ценой ошибки недостаточны. Тестовая выборка содержит 1625 объектов, из них около 842 ядовитых. На данном наборе данных почти все модели показывают точность, близкую к 1.00, и различия между ними составляют доли процента, то есть лежат в пределах случайных колебаний и не могут служить основанием для выбора алгоритма. Поэтому для надёжных выводов необходим учёт не только accuracy, но и матриц ошибок, прежде всего числа ложноположительных (FP) и ложноотрицательных (FN) исходов.

Ключевая метрика — recall класса «ядовитый», а не accuracy. При цене ошибки, когда ядовитый гриб определён как съедобный (FN), последствия могут быть фатальными, а ложная тревога (FP) приводит лишь к отказу от пригодного в пищу гриба. Поэтому основным критерием выбран recall для класса «ядовитый», а precision используется как контроль, чтобы не допустить «накрутки» recall простым отнесением всех объектов к ядовитым.

Высокий recall сам по себе не означает лучшего качества. Если модель чаще относит грибы к ядовитым, её recall растёт, но precision падает, и практическая ценность снижается. Поэтому модели сравниваются совместно по recall, precision и матрице ошибок.

Ансамбли стабильнее одиночного дерева (меньший разброс метрик между разбиениями), что важно при использовании модели в реальной практике.

Применимость методов

– **Одиночное дерево.** Преимущество: простота и интерпретируемость (правила вида «если запах такой-то, то гриб ядовит» понятны человеку). Недостатки: склонность к переобучению, наибольшая нестабильность, чувствительность к небольшим изменениям обучающей выборки. Подходит как интерпретируемая базовая модель, но не как основной классификатор для задачи с высокой ценой ошибки.

– **Случайный лес.** Устойчив, показывает высокие recall и precision, менее склонен к переобучению, чем одиночное дерево, допускает оценку важности признаков. Хороший компромисс между качеством и интерпретируемостью.

– **AdaBoost.** На данном наборе данных показывает результаты чуть ниже, чем у градиентного бустинга, и более чувствителен к шуму и выбросам. Для задачи с приоритетом recall менее предпочтителен.

– **XGBoost и CatBoost.** Наилучший баланс: на тестовой выборке достигают recall и precision, близких к 1.00, практически не допускают FN (ядовитый не пропускается) и имеют минимальное число ошибок в матрице. Между собой статистически не различаются.

Выбор алгоритма для задачи с высокой ценой ошибки

В задаче определения ядовитости грибов пропуск ядовитого (FN) опаснее ложной тревоги (FP), так как ложноположительный результат приводит лишь к отказу от съедобного гриба, а пропущенный ядовитый может привести к отравлению. Поэтому основной метрикой выбран **recall класса «ядовитый»**, а precision и матрица ошибок используются, чтобы не допустить «накрутки» recall простым увеличением числа положительных предсказаний.

Предпочтительным алгоритмом считаем **градиентный бустинг (CatBoost или XGBoost)**: он показывает recall и precision, близкие к 1.00, практически не пропускает ядовитые грибы и устойчивее одиночного дерева. Различие между XGBoost и CatBoost в пределах случайных колебаний. Случайный лес также показывает высокие результаты и может использоваться как надёжная альтернатива, особенно если важна интерпретируемость (важность признаков). Одиночное дерево и AdaBoost дают чуть более низкий recall и поэтому для задачи с высокой ценой ошибки менее надёжны; одиночное дерево при этом остаётся полезным как интерпретируемая базовая модель. Если требуется ещё более высокий recall, надёжнее снижать порог классификации, чем менять алгоритм.

Ограничения

– тестовая выборка содержит 1625 объектов, из них около 842 ядовитых; при почти идеальном разделении классов оценки метрик имеют малый разброс, но на других данных (с шумом, пропусками, дисбалансом) результаты могут отличаться;
– гиперпараметры не подбирались, использованы разумные фиксированные значения;
– пропуски в признаке stalk-root (обозначены ?) кодировались как отдельная категория и не восстанавливались; их обработка и подбор гиперпараметров по кросс-валидации

могут улучшить результаты;
– числа для XGBoost и CatBoost могут слегка отличаться при запуске на другой машине или версии библиотеки (случайные подвыборки в алгоритме); выводы от этого не меняются.

Вывод: на практике сравнена работа нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений на наборе Mushroom Classification. Показано, что для задачи с высокой ценой ошибки, где приоритетом является recall класса «ядовитый», наиболее предпочтителен градиентный бустинг (CatBoost или XGBoost), тогда как одиночное дерево пригодно лишь как интерпретируемая базовая модель, а AdaBoost — наименее подходящий вариант.