

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине: «Интеллектуальный анализ данных»
Тема: «Предобучение нейронных сетей с использованием RBM»

Выполнила:
Студентка 4 курса
Группы ИИ-25
Мархель А.Д.
Проверила:
Андренко К.В.

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью RBM.

Общее задание

1. Взять за основу нейронную сеть из лабораторной работы №3. Выполнить обучение с предобучением, используя стек ограниченных машин Больцмана (RBM – Restricted Boltzmann Machine), алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев как RBM выбрать самостоятельно;
2. Сравнить результаты, полученные при: обучении без предобучения (ЛР 3); обучении с предобучением, используя автоэнкодерный подход (ЛР 3); обучении с предобучением, используя RBM;
3. Обучить модели на данных из ЛР 2, сравнить результаты по схеме из пункта 2;
4. Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет.

Вариант 6

№ варианта	Выборка	Тип задачи	Целевая переменная
6	Physicochemical Properties of Protein Tertiary Structure (UCI, CASP.csv)	регрессия	RMSD
ЛР №2	Wisconsin Diagnostic Breast Cancer (WDBC, wdbc.data)	классификация	Diagnosis (B / M)

Ход работы

1. Выборки и подготовка данных

Использованы те же выборки и та же подготовка, что в ЛР №3. Physicochemical Properties of Protein Tertiary Structure (вариант 6, регрессия): 45 730 объектов, 9 вещественных физико-химических признаков F1–F9 и целевая переменная RMSD (Å), пропусков нет. WDBC из ЛР №2 (классификация): 569 объектов (357 доброкачественных B и 212 злокачественных M), 30 вещественных признаков; положительный класс – M.

Выборка делится на обучающую, валидационную и тестовую части 60 / 20 / 20 (WDBC – со стратификацией): Protein – 27 438 / 9 146 / 9 146, WDBC – 341 / 114 / 114. Стандартизация признаков (и RMSD для регрессии) рассчитывается только по обучающей части. Предобучение использует только признаки обучающей выборки (без целевой переменной), валидационная часть служит для выбора лучшей эпохи, тестовая – только для итоговой оценки.

Эксперименты повторяются для нескольких seed (Protein – 5, WDBC – 10); seed задаёт и разбиение, и начальные веса.

2. Сеть (ЛР 3)

Выборка	Архитектура	Слоёв с весами	Активация скрытых слоёв	Выход	Потери
Protein (регрессия)	9-128-64-32-16-1	5 (4 скрытых)	ReLU	1 линейный нейрон	MSE
WDBC (классификация)	30-64-32-16-8-2	5 (4 скрытых)	ReLU	2 логита (softmax в CE)	Cross-Entropy

Архитектура, оптимизатор (Adam, lr = 0,001), число эпох тонкой настройки (100 для Protein, 150 для WDBC), размер мини-батча max(16, min(256, N/8)), разбиения и seed полностью совпадают с ЛР №3. Поэтому результаты режимов «без предобучения» и «автоэнкодеры» воспроизводятся из ЛР №3 с точностью до всех приведённых знаков (например, RMSE 3,871 и 3,908 Å на Protein), что подтверждает корректность сравнения.

3. Предобучение стеклом RBM

RBM – двухслойная сеть из видимого слоя v (n нейронов) и скрытого слоя h (m нейронов) с матрицей связей W ($n \times m$), порогами видимых b и скрытых c нейронов; связей внутри слоя нет. В отличие от автоэнкодера, у которого кодер и декодер имеют разные матрицы и обучаются обратным распространением ошибки, RBM использует одну матрицу W в обе стороны (W при прямом проходе и W^T при обратном) и обучается алгоритмом Contrastive Divergence (CD-1). Для каждой RBM на мини-батче из лекции выполняется:

1. для скрытых нейронов вычисляется $h_1 = f(v_1 \cdot W + c)$ (для логистических нейронов – вероятность $P(h = 1 \mid v_1) = \text{sigm}(v_1 \cdot W + c)$); состояния логистических нейронов разыгрываются: $h = 1$, если $h_1 > \text{rand}$;
2. реконструкция видимого слоя: $v_2 = f_{\text{vis}}(h \cdot W^T + b)$;
3. повторное вычисление скрытого слоя: $h_2 = f(v_2 \cdot W + c)$;
4. обновление параметров: $\Delta W = \alpha \cdot (v_1^T h_1 - v_2^T h_2) / N$, $\Delta b = \alpha \cdot \text{mean}(v_1 - v_2)$, $\Delta c = \alpha \cdot \text{mean}(h_1 - h_2)$ – разность положительной фазы (на реальных данных) и отрицательной (на реконструкции); как в лекции используется моментум (0,5 в первых 5 эпохах, затем 0,9).

Код программы:

```
def run_modes(split, task, sizes, act_name, seed, cfg):
    """Три модели стартуют из одних и тех же случайных весов; одинаковые разбиение,
    оптимизатор,
    порядок мини-батчей и число эпох тонкой настройки. Различается только предобучение."""
    set_seed(seed)
```

```

base = build_mlp(sizes, act_name)

plain = copy.deepcopy(base)
h = fit(plain, split, task, cfg, seed, pretrained=False)
out = {"plain": finish(plain, h, split, task, cfg)}

ae = copy.deepcopy(base)
curves = pretrain_layers(ae, split["X_tr"], act_name, cfg, seed)      # только train, без
меток
h = fit(ae, split, task, cfg, seed, pretrained=True)
out["ae"] = finish(ae, h, split, task, cfg, curves)

rbm = copy.deepcopy(base)
curves = pretrain_rbm(rbm, split["X_tr"], act_name, cfg, seed)      # только
train, без меток
h = fit(rbm, split, task, cfg, seed, pretrained=True)
out["rbm"] = finish(rbm, h, split, task, cfg, curves)
return out

```

```

@torch.no_grad()
def pretrain_rbm(model, X, act_name, cfg, seed):
    """Предобучение скрытых слоёв model стеком RBM. Возвращает кривые ошибки реконструкции
    (средний квадрат ошибки на один элемент) по эпохам для каждой RBM."""
    gen = torch.Generator().manual_seed(seed + 3000)
    batch = batch_size_for(len(X))
    f_hid = ACTIVATIONS[act_name]()
    logistic = act_name == "sigmoid"
    H = X
    curves = []
    for li, lin in enumerate(linear_layers(model)[: -1]):
        n_vis, n_hid = lin.in_features, lin.out_features
        f_vis = (lambda z: z) if li == 0 else f_hid
        rates = cfg.rbm_rates[act_name]
        rate = rates[min(li, len(rates) - 1)]

        W = 0.1 * torch.randn(n_vis, n_hid, generator=gen)
        b = torch.zeros(n_vis)
        c = -torch.ones(n_hid) if logistic else torch.zeros(n_hid)
        vW, vb, vc = torch.zeros_like(W), torch.zeros_like(b), torch.zeros_like(c)

        curve = []
        for epoch in range(cfg.rbm_epochs):
            momentum = cfg.rbm_start_momentum if epoch < 5 else cfg.rbm_final_momentum
            err = 0.0
            for idx in _batches(len(H), batch, gen):
                v1 = H[idx]
                h1 = f_hid(v1 @ W + c)
                h_s = (h1 > torch.rand(h1.shape, generator=gen)).float() if logistic else h1
                v2 = f_vis(h_s @ W.T + b)
                h2 = f_hid(v2 @ W + c)

                n = len(idx)
                vW = vW * momentum + rate * ((v1.T @ h1 - v2.T @ h2) / n -
cfg.rbm_weight_decay * W)
                vb = vb * momentum + rate * (v1 - v2).sum(0) / n
                vc = vc * momentum + rate * (h1 - h2).sum(0) / n
                W += vW
                b += vb
                c += vc
                err += ((v2 - v1) ** 2).sum().item()
            curve.append(err / (len(H) * n_vis))
            if err / len(H) < cfg.rbm_min_error:
                break
        curves.append(curve)

        lin.weight.copy_(W.T)      # веса RBM -> слой сети
        lin.bias.copy_(c)         # пороги скрытых нейронов -> смещения слоя
        H = f_hid(H @ W + c)      # вход следующей RBM
    return curves

```

4. Схема сравнения и метрики

Для каждого seed три модели – без предобучения, с предобучением автоэнкодерами, с предобучением RBM – стартуют из одних и тех же случайных весов, на одном разбиении, с одним оптимизатором, одним порядком мини-батчей и одним числом эпох тонкой настройки (функция run_modes, файл experiment.py). Различается только предобучение. Итоговой считается модель с минимальной ошибкой на валидации.

- **Регрессия (Protein):** RMSE, MAE, R^2 в ангстремах; MAPE считается по объектам с $\text{RMSD} \geq 1 \text{ \AA}$ (при $\text{RMSD} = 0$, а в выборке таких 272 объекта, MAPE не определён); $\text{WAPE} = \Sigma|e|/\Sigma|y| \cdot 100 \%$ учитывает все объекты.
- **Классификация (WDBC):** Efficiency, % (доля верных ответов по argmax), F1, Precision, Recall для класса M, матрица ошибок.
- **Динамика обучения:** ошибка на валидации до тонкой настройки (эпоха 0); «колебательность» – средний модуль изменения val loss между эпохами (после 10-й) в % от средней val loss; «шум» – СКО отклонений val loss от скользящего среднего по 5 эпохам в % от средней val loss; число эпох до заданного порога val loss.
- **Статистика:** среднее $\pm$ СКО по запускам, значимость – парный t-тест (p-value) для пар «автоэнкодеры – без предобучения», «RBM – без предобучения», «RBM – автоэнкодеры».

Результат

1. Protein Tertiary Structure (вариант 6, регрессия)

Качество на тестовой выборке, среднее $\pm$ СКО по 5 запускам (MAPE – по объектам с $\text{RMSD} \geq 1 \text{ \AA}$):

Режим	RMSE, $\text{\AA}$	MAE, $\text{\AA}$	R^2	MAPE, %	WAPE, %
Без предобучения	3.871 ± 0.063	2.677 ± 0.062	0.599 ± 0.011	53.897 ± 3.729	34.564 ± 0.833
Автоэнкодеры	3.908 ± 0.065	2.788 ± 0.047	0.591 ± 0.013	56.434 ± 1.643	35.997 ± 0.545
RBM	3.847 ± 0.065	2.640 ± 0.070	0.604 ± 0.012	52.201 ± 3.018	34.089 ± 0.799

Парный t-тест (p-value):

Показатель	Автоэнкодеры – без предобучения	RBM – без предобучения	RBM – автоэнкодеры
RMSE	0,030	0,198	0,005
MAE	0,002	0,107	0,001
R^2	0,031	0,199	0,005

MAPE	0,104	0,254	0,034
WAPE	0,002	0,109	0,001

Предобучение стеклом RBM даёт номинально лучшие значения всех метрик (RMSE 3,847 против 3,871 Å без предобучения, R^2 0,604 против 0,599), но отличие от обучения без предобучения статистически незначимо ($p = 0,11–0,25$). Автоэнкодерное предобучение, наоборот, немного ухудшает результат (RMSE 3,908 Å, $p = 0,03$), и RBM значимо превосходит его ($p \leq 0,034$ по всем метрикам). Все разности малы по сравнению с погрешностью самой модели (MAPE $\approx 52–56\%$).




Рисунок 1 – Ошибка на валидации при тонкой настройке (Protein)

Динамика обучения (после 10-й эпохи; показатели в % от средней val loss):

Режим	Val loss, эпоха 0	Лучшая эпоха	Колебательность, %	Шум val-кривой, %	Эпох с ростом val, %
Без предобучения	1.013 ± 0.019	93.200 ± 6.834	2.419 ± 0.186	2.072 ± 0.258	45.333 ± 2.876
Автоэнкодеры	0.769 ± 0.028	97.200 ± 2.950	2.266 ± 0.304	1.952 ± 0.532	43.778 ± 2.166
RBM	0.775 ± 0.013	99.200 ± 0.837	2.402 ± 0.353	2.059 ± 0.310	45.556 ± 3.043

Оба вида предобучения снижают стартовую ошибку на валидации (0,769 и 0,775 против 1,013), но сглаживания процесса обучения нет: колебательность 2,27 % (автоэнкодеры) и 2,40 % (RBM) против 2,42 % без предобучения, $p = 0,10$ и $0,90$. Скорость сходимости: порог val loss $\leq 0,55$ достигается за 6,6 эпохи без предобучения, 7,6 – с автоэнкодерами и 5,2 – с RBM; минимум val loss равен $0,395 \pm 0,004$, $0,406 \pm 0,006$ и $0,387 \pm 0,002$ соответственно, т.е. RBM-вариант сходится быстрее и в лучшую точку, хотя на тесте выигрыш незначим.




Рисунок 2 – Ошибка реконструкции RBM при послойном предобучении (Protein, seed 0)




Рисунок 3 – Предсказанный и истинный RMSD на тесте (Protein, seed 0)

Логистическая активация

Лекция строит сеть из логистических нейронов; для такой сети RBM (с бинарными сэмплируемыми нейронами) полностью согласована со слоями. Результаты для логистической сети (3 запуска) приведены вместе с ReLU:

Активация	Режим	RMSE, Å	R ²	MAPE, %	Колеб., %	Шум, %
ReLU	Без предобучения	3.836 ± 0.057	0.604 ± 0.012	52.681 ± 3.583	2.503 ± 0.199	2.142 ± 0.339
ReLU	Автоэнкодеры	3.867 ± 0.044	0.598 ± 0.009	56.466 ± 1.949	2.347 ± 0.375	2.126 ± 0.660
ReLU	RBM	3.800 ± 0.018	0.611 ± 0.004	50.114 ± 1.249	2.509 ± 0.454	2.153 ± 0.396
Logistic (sigmoid)	Без предобучения	4.662 ± 0.057	0.415 ± 0.015	87.035 ± 4.021	0.754 ± 0.099	0.728 ± 0.134
Logistic (sigmoid)	Автоэнкодеры	4.435 ± 0.020	0.471 ± 0.004	77.757 ± 1.689	1.031 ± 0.033	0.901 ± 0.128
Logistic (sigmoid)	RBM	4.620 ± 0.025	0.426 ± 0.006	81.247 ± 1.061	0.634 ± 0.072	0.575 ± 0.134

Логистическая сеть обучается заметно хуже ReLU-сети (RMSE 4,66 против 3,84 Å без предобучения). Автоэнкодерное предобучение для неё полезно (RMSE 4,435, $p = 0,035$), RBM-предобучение значимого эффекта не даёт (RMSE 4,620, $p = 0,47$ относительно сети без предобучения) и уступает автоэнкодерам ($p = 0,002$). Кривая валидации при RBM-инициализации самая гладкая (колебательность 0,63 % против 0,75 % без предобучения и 1,03 % у автоэнкодеров), но это результат трёх запусков.

Малые обучающие выборки

Подвыборки обучающей части (валидационная и тестовая прежние, 5 запусков, ReLU):

Объектов в train	Режим	RMSE, Å	R ²	MAPE, %
250	Без предобучения	5.235 ± 0.143	0.266 ± 0.037	99.076 ± 5.864
	Автоэнкодеры	5.230 ± 0.140	0.267 ± 0.039	99.213 ± 5.737
	RBM	5.248 ± 0.159	0.262 ± 0.045	101.302 ± 7.658
1000	Без предобучения	4.858 ± 0.057	0.368 ± 0.015	81.051 ± 2.268
	Автоэнкодеры	4.908 ± 0.085	0.355 ± 0.021	88.770 ± 5.198
	RBM	4.888 ± 0.062	0.360 ± 0.015	86.147 ± 1.554
5000	Без предобучения	4.379 ± 0.049	0.487 ± 0.012	69.996 ± 1.269
	Автоэнкодеры	4.436 ± 0.055	0.473 ± 0.012	71.508 ± 2.977
	RBM	4.376 ± 0.040	0.487 ± 0.011	70.474 ± 4.735
27438	Без предобучения	3.871 ± 0.063	0.599 ± 0.011	53.897 ± 3.729
	Автоэнкодеры	3.908 ± 0.065	0.591 ± 0.013	56.434 ± 1.643
	RBM	3.847 ± 0.065	0.604 ± 0.012	52.201 ± 3.018




Рисунок 4 – Зависимость RMSE на тесте от размера обучающей выборки (Protein)

При 250, 1 000 и 5 000 объектах все три режима различаются меньше, чем их разброс между запусками (например, при 250 объектах RMSE 5,235 / 5,230 / 5,248 Å): на выборке Protein ни один вид предобучения не помогает при малом числе объектов.

2. WDBC (данные из ЛР №2, классификация)

Качество на тестовой выборке, среднее $\pm$ СКО по 10 запускам (положительный класс – М):

Режим	Efficiency, %	F1	Precision	Recall
Без предобучения	96.842 $\pm$ 1.812	0.957 $\pm$ 0.025	0.963 $\pm$ 0.036	0.953 $\pm$ 0.035
Автоэнкодеры	96.404 $\pm$ 1.129	0.951 $\pm$ 0.015	0.963 $\pm$ 0.033	0.941 $\pm$ 0.030
RBM	96.579 $\pm$ 1.337	0.953 $\pm$ 0.019	0.970 $\pm$ 0.032	0.939 $\pm$ 0.034

Парный t-тест (p-value):

Показатель	Автоэнкодеры – без предобучения	RBM – без предобучения	RBM – автоэнкодеры
Efficiency	0,177	0,468	0,443
F1	0,172	0,405	0,512
Precision	0,924	0,093	0,092
Recall	0,177	0,138	0,716

Значимых различий в качестве нет ни между одной парой режимов: Efficiency 96,84 % (без предобучения), 96,40 % (автоэнкодеры), 96,58 % (RBM). Матрицы ошибок, суммарные по 10 тестовым выборкам (строки – истина, столбцы – прогноз):

Режим	В $\rightarrow$ В	В $\rightarrow$ М	М $\rightarrow$ В	М $\rightarrow$ М
Без предобучения	700	16	20	404
Автоэнкодеры	700	16	25	399
RBM	703	13	26	398

WDBC: матрицы ошибок (сумма по 10 тестовым выборкам)




Рисунок 5 – Матрицы ошибок (WDBC, сумма по 10 тестовым выборкам)

RBM-сеть даёт наименьшее число ложных срабатываний (13 против 16), но чаще других пропускает злокачественные опухоли (26 против 20 без

предобучения), что соответствует чуть более высокой Precision (0,970) при чуть более низком Recall (0,939); различия не значимы. Для медицинской задачи число пропусков ($M \rightarrow B$) важнее числа ложных тревог, поэтому лучшим по этому критерию остаётся режим без предобучения, но разница находится в пределах случайной вариации.




Рисунок 6 – Ошибка (Cross-Entropy) на валидации при тонкой настройке (WDBC)

Динамика обучения:

Режим	Val loss, эпоха 0	Лучшая эпоха	Колебательность, %	Шум val-кривой, %	Эпох с ростом val, %
Без предобучения	0.725 ± 0.037	43.500 ± 53.757	2.505 ± 4.049	3.394 ± 6.612	74.429 ± 22.345
Автоэнкодеры	0.582 ± 0.124	22.900 ± 21.553	1.424 ± 1.060	1.649 ± 1.549	79.214 ± 14.100
RBM	0.365 ± 0.112	15.600 ± 16.277	0.974 ± 0.480	1.133 ± 0.837	82.000 ± 14.213

Здесь RBM-предобучение заметно эффективнее: стартовая ошибка на валидации 0,365 против 0,582 у автоэнкодеров и 0,725 без предобучения; порог $\text{Cross-Entropy} \leq 0,2$ достигается за 1,9 эпохи (4,6 – у автоэнкодеров, 8,7 – без предобучения; без предобучения один запуск порога не достиг). Минимум val loss близок у всех (0,098 / 0,083 / 0,085). Кривая валидации RBM-сети самая гладкая: колебательность 0,97 % против 1,42 % (автоэнкодеры) и 2,51 % (без предобучения), шум 1,13 % против 1,65 % и 3,39 %; статистически значимой разница не стала ($p = 0,23$ относительно сети без предобучения, $p = 0,058$ относительно автоэнкодеров). После 10–20-й эпохи на малой выборке (341 объект) val loss растёт у всех сетей – переобучение, поэтому важен выбор лучшей эпохи по валидации.




Рисунок 7 – Ошибка реконструкции RBM при предобучении (WDBC, seed 0)

Логистическая активация

5 запусков:

Активация	Режим	Efficiency, %	F1	Колеб., %	Шум, %
ReLU	Без предобучения	96.316 ± 1.902	0.950 ± 0.026	1.491 ± 1.435	1.684 ± 2.502
ReLU	Автоэнкодеры	96.140 ± 1.468	0.947 ± 0.020	1.392 ± 1.225	1.651 ± 1.957
ReLU	RBM	96.316 ± 1.301	0.949 ± 0.019	0.920 ± 0.643	1.047 ± 1.087
Logistic (sigmoid)	Без предобучения	97.544 ± 1.144	0.966 ± 0.016	1.991 ± 0.242	0.438 ± 0.162
Logistic (sigmoid)	Автоэнкодеры	96.667 ± 1.687	0.953 ± 0.026	2.318 ± 0.837	0.869 ± 0.694
Logistic (sigmoid)	RBM	96.667 ± 2.094	0.954 ± 0.030	1.567 ± 0.556	0.832 ± 0.814

С логистической активацией качество сопоставимо (96,7–97,5 %), предобучение его не улучшает (без предобучения даже чуть выше, но в пределах СКО 1–2 п.п.). Кривая валидации логистической сети самая гладкая из всех (шум 0,4–0,9 %).

Малые обучающие выборки

Подвыборки обучающей части (валидационная и тестовая прежние, 10 запусков, ReLU):

Объектов в train	Режим	Efficiency, %	F1
30	Без предобучения	88.333 ± 18.331	0.882 ± 0.127
	Автоэнкодеры	94.211 ± 2.930	0.922 ± 0.038
	RBM	93.947 ± 2.757	0.917 ± 0.038
60	Без предобучения	89.035 ± 18.448	0.893 ± 0.127
	Автоэнкодеры	95.175 ± 1.861	0.936 ± 0.021

	RBM	95.526 ± 2.427	0.940 ± 0.030
120	Без предобучения	96.053 ± 1.324	0.947 ± 0.017
	Автоэнкодеры	96.053 ± 0.745	0.947 ± 0.009
	RBM	96.316 ± 0.906	0.950 ± 0.011
341	Без предобучения	96.842 ± 1.812	0.957 ± 0.025
	Автоэнкодеры	96.404 ± 1.129	0.951 ± 0.015
	RBM	96.579 ± 1.337	0.953 ± 0.019




Рисунок 8 – Зависимость Efficiency на тесте от размера обучающей выборки (WDBC)

При 30 и 60 объектах оба вида предобучения дают более высокую среднюю точность (94,2 % и 93,9 % против 88,3 % при 30 объектах; 95,2 % и 95,5 % против 89,0 % при 60) и в несколько раз меньший разброс (СКО 2,8–2,9 п.п. против 18,3 п.п.). Проверка по запускам показала, что причина – один запуск без предобучения (seed 6), в котором сеть «умерла» и дала 36,8 %; с автоэнкодерами тот же запуск дал 95,6 %, с RBM – 93,9 % (при 30 объектах). Без этого запуска средние практически равны (при 30 объектах: 94,06 % без предобучения, 94,06 % автоэнкодеры, 93,96 % RBM; при 60: 94,83 / 95,03 / 95,21 %). Таким образом, на очень малых выборках оба вида предобучения повышают надёжность обучения (защищают от неудачного старта), но не точность в типичном случае. При 120 и более объектах режимы равноценны.

3. Сравнение трёх режимов

Показатель	Без предобучения	Автоэнкодеры (ЛР3)	RBM (ЛР4)
Protein: RMSE, Å (ReLU)	$3,871 \pm 0,063$	$3,908 \pm 0,065$ (хуже, $p = 0,03$)	$3,847 \pm 0,065$ (n.s., $p = 0,20$)
Protein: R^2	0,599	0,591	0,604
Protein: val loss, эпоха 0	1,013	0,769	0,775
Protein: эпох до val loss $\leq 0,55$	6,6	7,6	5,2
Protein: RMSE, Logistic	4,662	4,435 (лучше, $p = 0,035$)	4,620 (n.s.)

WDBC: Efficiency, %	96,84 ± 1,81	96,40 ± 1,13	96,58 ± 1,34
WDBC: F1	0,957	0,951	0,953
WDBC: val loss, эпоха 0	0,725	0,582	0,365
WDBC: эпох до CE ≤ 0,2	8,7	4,6	1,9
WDBC: колебательность val, %	2,51	1,42	0,97
WDBC: 30 объектов, Efficiency, %	88,3 ± 18,3 (1 сбой)	94,2 ± 2,9	93,9 ± 2,8

Выводы по сравнению

- **Итоговое качество:** ни автоэнкодерное, ни RBM-предобучение не дало статистически значимого улучшения итогового качества ReLU-сети на обеих выборках: данных достаточно для обучения с нуля. Номинально лучший результат на Protein показал RBM (RMSE 3,847 Å), и он значимо лучше автоэнкодерного варианта ($p = 0,005$), который на Protein слегка ухудшил результат; на WDBC все три режима равноценны (96,4–96,8 %).
- **Начальная точка и скорость сходимости:** RBM-предобучение даёт наименьшую стартовую ошибку на WDBC (0,365 против 0,582 и 0,725) и самую быструю сходимость (1,9 эпохи до порога против 4,6 и 8,7); на Protein стартовая ошибка у RBM и автоэнкодеров одинакова ($\approx 0,77$ против 1,01), порог достигается быстрее всего у RBM (5,2 эпохи).
- **Сглаживание:** на WDBC колебательность val-кривой убывает в ряду «без предобучения → автоэнкодеры → RBM» (2,51 → 1,42 → 0,97 %), но различия незначимы из-за разброса между запусками; на Protein сглаживания нет ни у одного режима.
- **Малые выборки:** на очень малых выборках WDBC (30–60 объектов) оба вида предобучения защищают от неудачной инициализации, но не повышают точность в типичном случае; на Protein при малых выборках разницы нет.
- **Выбор метода:** для сети с ReLU RBM должна быть согласована со слоями сети (ReLU-нейроны, порог 0, скорость обучения 0,001); бинарная логистическая RBM с порогом -1 из лекции для ReLU-сети не подходит (нейроны «умирают»). Для логистической сети (как в лекции) на Protein лучше сработали автоэнкодеры, а не RBM. RBM обучается проще (без обратного распространения), но имеет больше гиперпараметров, чувствительных к масштабу (скорость, моментум, пороги).

Вывод

Вывод: научилась осуществлять предобучение нейронных сетей с помощью RBM. Реализовано жадное послойное предобучение четырёх скрытых слоёв сети из ЛР №3 стеком ограниченных машин Больцмана

(Contrastive Divergence CD-1, моментум, условие останова по числу эпох) с последующим обучением выходного слоя и тонкой настройкой. Выполнено сравнение трёх режимов – без предобучения, с автоэнкодерами (ЛР №3) и с RBM – на выборке Protein Tertiary Structure (вариант 6, регрессия RMSD) и на выборке WDBC из ЛР №2 (классификация) на нескольких разбиениях с проверкой парным t-тестом. Итоговое качество на достаточно больших выборках от вида предобучения не зависит (Protein: RMSE 3,847 / 3,871 / 3,908 Å для RBM / без предобучения / автоэнкодеров; WDBC: Efficiency 96,6 / 96,8 / 96,4 %), при этом RBM-предобучение даёт самую низкую начальную ошибку и самую быструю сходимость на WDBC и значимо превосходит автоэнкодерное предобучение на Protein. На очень малых выборках предобучение повышает надёжность обучения.