

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

По дисциплине: «Интеллектуальный анализ данных»

Тема: «Автоэнкодеры»

Выполнил:

Студент 4 курса

Группы ИИ-25

Трошин И.Д.

Проверила:

Андренко К.В.

Цель работы: научиться применять автоэнкодеры для осуществления визуализации данных и их анализа.

Общее задание

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент с использованием нейросетевой модели автоэнкодера (с двумя и тремя нейронами в среднем слое);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Реализовать метод t-SNE для визуализации данных (использовать также 2 и 3 компонента), построить соответствующую визуализацию;
4. Применить к данным метод PCA (2 и 3 компонента), реализованный в ЛР №1, сделать выводы;
5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Важные замечания

1. При реализации автоэнкодера архитектуру (количество слоев, нейронов, функции активации), а также параметры обучения подбирать экспериментально (рекомендовано начинать с более простых архитектур, использовать функции активации ReLU (особенно в случае глубоких НС), а также оптимизатор Adam);
2. Рекомендуется использовать вариант реализации метода t-SNE, включенный в пакет `sklearn` (`sklearn.manifold.TSNE`);
3. Для t-SNE рекомендуется выполнить визуализацию при различных значениях перплексивности (**perplexity**) и отобрать наиболее презентативную (рекомендуется выбирать значение данного параметра из диапазона от 20 до 60);
4. Для начальной инициализации t-SNE можно использовать метод PCA (опция **init**).

Вариант 13

№	Выборка	Класс
13	<u>Rice (Cammeo and Osmancik)</u>	Class

Ход работы

Rice — набор данных о зёрнах риса, предназначенный для классификации зёрен по их физическим и геометрическим характеристикам. Исходный файл имеет структуру:

Поле	Описание
Area	Площадь зерна риса

Perimeter	Периметр зерна
Major_Axis_Length	Длина большой оси зерна
Minor_Axis_Length	Длина малой оси зерна
Eccentricity	Эксцентриситет зерна
Convex_Area	Площадь выпуклой оболочки зерна
Extent	Отношение площади зерна к площади ограничивающего прямоугольника
Class	Класс (сорт) риса

Каждая строка соответствует одному образцу зерна риса. Первые семь столбцов содержат числовые признаки, характеризующие геометрические свойства зерна, а последний столбец Class содержит его класс.

Пример исходных данных:

Area	Perimeter	Major_Axis_Length	Minor_Axis_Length	Eccentricity	Convex_Area	Extent	Class
15231	525.579	229.750	85.094	0.929	15617	0.573	Cammeo
14656	494.311	206.020	91.731	0.895	15072	0.615	Cammeo
14634	501.122	214.107	87.768	0.912	14954	0.693	Cammeo

В датасете представлены два класса зёрен риса:

- Cammeo
- Osmancik

Таким образом, для задач машинного обучения Class является целевой переменной, а Area, Perimeter, Major_Axis_Length, Minor_Axis_Length, Eccentricity, Convex_Area и Extent — входными признаками.

Для PCA, t-SNE и автоэнкодера используются семь числовых признаков. Столбец Class не используется непосредственно при построении двумерного представления, а применяется для последующей визуализации и анализа того, насколько хорошо два класса разделяются в полученном пространстве признаков.


Используется полносвязный симметричный автоэнкодер с архитектурой:

7 -> 16 -> 8 -> 2/3 -> 8 -> 16 -> 7

Входной слой содержит 7 признаков датасета Rice. Энкодер последовательно уменьшает размерность до 16 и 8 нейронов, после чего формирует латентное представление из 2 или 3 нейронов. Далее декодер восстанавливает исходные 7 признаков. В скрытых слоях используется функция активации ReLU, а для обучения применяется MSE Loss и оптимизатор Adam.


Результат Автоэнкодер:

2 компоненты




АВТОЭНКОДЕР — 2 КОМПОНЕНТЫ

Epoch 1/300 Loss: 1.005332
Epoch 25/300 Loss: 0.132413
Epoch 50/300 Loss: 0.119659
Epoch 75/300 Loss: 0.107430
Epoch 100/300 Loss: 0.096382
Epoch 125/300 Loss: 0.091033
Epoch 150/300 Loss: 0.087545
Epoch 175/300 Loss: 0.084718
Epoch 200/300 Loss: 0.082221
Epoch 225/300 Loss: 0.080309
Epoch 250/300 Loss: 0.078410
Epoch 275/300 Loss: 0.076528
Epoch 300/300 Loss: 0.075291




3 компоненты




АВТОЭНКОДЕР — 3 КОМПОНЕНТЫ

Epoch 1/300 Loss: 1.016081
Epoch 25/300 Loss: 0.052140
Epoch 50/300 Loss: 0.003180
Epoch 75/300 Loss: 0.002406
Epoch 100/300 Loss: 0.002136
Epoch 125/300 Loss: 0.001972
Epoch 150/300 Loss: 0.001811
Epoch 175/300 Loss: 0.001689
Epoch 200/300 Loss: 0.001636
Epoch 225/300 Loss: 0.001602
Epoch 250/300 Loss: 0.001610
Epoch 275/300 Loss: 0.001552
Epoch 300/300 Loss: 0.001531




PCA:

2 компоненты



PCA — 2 КОМПОНЕНТЫ
Доля объяснённой дисперсии по компонентам:
PC1: 0.654140 (65.41%)
PC2: 0.214251 (21.43%)
PC1 + PC2: 0.868391 (86.84%)


3 компоненты



PCA — 3 КОМПОНЕНТЫ
PC1: 65.41%
PC2: 21.43%
PC3: 12.87%
PC1 + PC2 + PC3: 99.71%


t-SNE:

2 компоненты



t-SNE: 2 компоненты, perplexity = 20
KL divergence: 1.076940
t-SNE: 2 компоненты, perplexity = 30
KL divergence: 1.062811
t-SNE: 2 компоненты, perplexity = 40
KL divergence: 1.039760
t-SNE: 2 компоненты, perplexity = 50
KL divergence: 1.017636
t-SNE: 2 компоненты, perplexity = 60
KL divergence: 0.995513

3 компоненты



t-SNE: 3 компоненты, perplexity = 20
KL divergence: 0.929680
t-SNE: 3 компоненты, perplexity = 30
KL divergence: 0.914783
t-SNE: 3 компоненты, perplexity = 40
KL divergence: 0.879398
t-SNE: 3 компоненты, perplexity = 50
KL divergence: 0.845278
t-SNE: 3 компоненты, perplexity = 60
KL divergence: 0.812905

1. Как влияет предварительная стандартизация признаков риса на качество сжатия автоэнкодером?
2. Совпадают ли результаты кластеризации классов на 2D-визуализациях автоэнкодера, t-SNE и PCA для Rice?

1) В анализ вошло 7 признаков:

Стандартизация приводит признаки к сопоставимому масштабу, поэтому признаки с большими числовыми значениями не доминируют при обучении. Это улучшает качество и корректность сжатия автоэнкодером.

2) Потери информации при проецировании

Полностью результаты не совпадают. PCA, автоэнкодер и t-SNE используют разные принципы снижения размерности, поэтому расположение и разделение Cammeo и Osmancik отличаются. При этом общая структура классов может сохраняться.

Вывод: научился применять автоэнкодеры для осуществления визуализации данных и их анализа.