Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5

По дисциплине: «Интеллектуальный анализ данных»
Тема: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: на практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 13

Вариант 13

- Car Evaluation (UCI)
- Оценить безопасность автомобиля (классы: unacc, acc, good, vgood)
- **Задания:**
    1. Загрузите данные. Все признаки категориальные, поэтому используйте OrdinalEncoder или OneHotEncoder;
    2. Разделите выборку;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Сравните общую точность моделей;
    5. Проанализируйте, какие признаки дерево решений посчитало наиболее важными (feature_importances_).

Ход работы

1. Загрузка датасета

Набор Car Evaluation (UCI) содержит 1728 автомобилей и 6 категориальных признаков:

Признак	Описание	Значения
buying	закупочная цена	low, med, high, vhigh
maint	стоимость обслуживания	low, med, high, vhigh
doors	число дверей	2, 3, 4, 5more
persons	вместимость, чел.	2, 4, more
lug_boot	размер багажника	small, med, big
safety	оценка безопасности	low, med, high

Целевая переменная class принимает 4 значения: unacc (неприемлемо) у 1210 автомобилей (70.02 %), acc (приемлемо) у 384 (22.22 %), good (хорошо) у 69 (3.99 %), vgood (отлично) у 65 (3.76 %). Классы сильно несбалансированы.

Файл не содержит строки заголовка, поэтому имена столбцов заданы вручную. Пропусков нет. Набор представляет собой полный перебор всех комбинаций значений признаков (4·4·4·3·3·3 = 1728), поэтому дубликатов нет. Значения признаков распределены равномерно: buying, maint и doors по 432 записи на каждое значение, persons, lug_boot и safety по 576.

Все признаки категориальные и имеют естественный порядок, поэтому применён OrdinalEncoder с явно заданным порядком категорий (например, low < med < high < vhigh). Целевая переменная закодирована с помощью LabelEncoder.

2. Разделение на обучающую и тестовую выборки

Разбиение 70/30 со стратификацией по классу (random_state = 42):

Выборка	Объектов	unacc	acc	good	vgood
Обучающая	1209	847	269	48	45
Тестовая	519	363	115	21	20

Стратификация сохраняет долю каждого класса в обеих выборках. Редкие классы good и vgood представлены в тестовой выборке лишь 21 и 20 объектами.

3. Обучение моделей

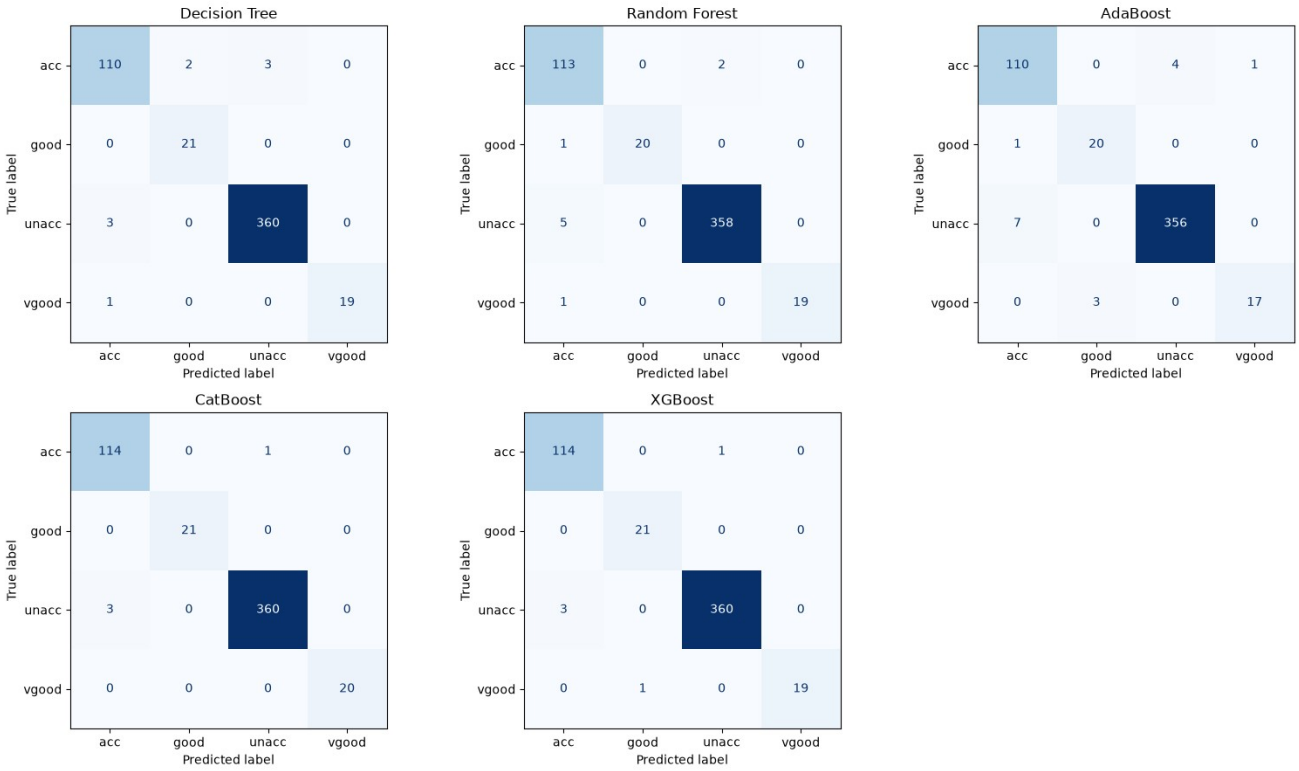
Модель	Основные параметры
Одиночное дерево	параметры по умолчанию (глубина не ограничена)
Случайный лес	200 деревьев
AdaBoost	200 деревьев глубиной max_depth = 3
XGBoost	200 деревьев
CatBoost	параметры по умолчанию, вывод отключён

4. Оценка моделей на тестовой выборке (результат работы программы)

Метрики: Accuracy, Precision, Recall, F1 (три последние с macro-усреднением по четырём классам, то есть все классы учитываются с равным весом независимо от размера) и ROC AUC (one-vs-rest, macro).

Модель	Accuracy	Precision	Recall	F1	ROC AUC
Decision Tree	0.9827	0.9674	0.9746	0.9703	0.9831
Random Forest	0.9827	0.9840	0.9678	0.9755	0.9990
AdaBoost	0.9692	0.9338	0.9349	0.9332	0.9933
CatBoost	0.9923	0.9929	0.9958	0.9943	0.9998
XGBoost	0.9904	0.9815	0.9833	0.9821	0.9998

Матрицы ошибок (строки: истинный класс, столбцы: предсказанный):



Число ошибочных предсказаний из 519: CatBoost 4, XGBoost 5, одиночное дерево 9, случайный лес 9, AdaBoost 16.

5. Сравнение результатов и выводы

5.1. Общие наблюдения

1. Все модели показывают высокое качество (accuracy 0.969 – 0.992). Датасет искусственный: класс автомобиля вычисляется из признаков по детерминированной иерархической модели, шума нет, поэтому даже одиночное дерево достигает accuracy 0.983.
2. Лучшие результаты у CatBoost по всем метрикам (accuracy 0.9923, F1 0.9943, ROC AUC 0.9998). Он допустил 4 ошибки и безошибочно определил редкие классы good и vgood. XGBoost близок к нему (accuracy 0.9904, ROC AUC 0.9998, 5 ошибок). Разница между ними составляет один объект из 519, то есть находится в пределах случайных колебаний.
3. Одиночное дерево и случайный лес имеют одинаковую accuracy (0.9827), но разный профиль ошибок. У леса выше precision (0.9840 против 0.9674), у дерева выше recall (0.9746 против 0.9678). Лес чаще относит автомобили класса unacc к acc (5 объектов против 3). Бэггинг не дал выигрыша в точности, так как в данных нет шума, который усреднение могло бы сгладить.
4. AdaBoost показал наихудший результат (accuracy 0.9692, F1 0.9332, 16 ошибок). Помимо путаницы между acc и unacc (11 ошибок), он ошибся на 3 объектах класса vgood, отнеся их к good, чего другие модели почти не допускают. Слабые деревья глубиной 3 хуже описывают сложные сочетания признаков, а перевзвешивание объектов на редких классах делает обучение нестабильным.
5. ROC AUC одиночного дерева (0.9831) заметно ниже, чем у ансамблей (0.9933 и выше). Дерево выдаёт практически жёсткие вероятности (0 или 1), а ансамбли дают более гладкие оценки, которые лучше ранжируют объекты.

6. Основная часть ошибок всех моделей приходится на пару классов acc и unacc, самых многочисленных и близких по смыслу: на их границе правила разбиения наиболее тонкие.

5.2. Применимость методов

- Одиночное дерево. Преимущества: высокая скорость обучения и интерпретируемость (правила можно прочитать). На данном наборе почти не уступает ансамблям по accuracy. Недостатки: наименьший ROC AUC среди всех моделей, чувствительность к составу обучающей выборки;
- случайный лес. Высокая precision и ROC AUC (0.9990), устойчивость к переобучению. На данном наборе не превосходит одиночное дерево по accuracy, но даёт более качественные вероятностные оценки;
- AdaBoost. На данном наборе наименее подходящий метод: самые низкие все метрики, кроме ROC AUC, и наибольшее число ошибок;
- XGBoost и CatBoost. Наилучшее качество по всем метрикам, включая редкие классы. Между собой практически не различаются. Платой за точность являются большее время обучения и меньшая интерпретируемость.

5.3. Важность признаков (одиночное дерево решений)

Признак	Важность
persons	0.2654
safety	0.2573
maint	0.1895
lug_boot	0.1217
buying	0.1009
doors	0.0652

Наиболее важными дерево считает persons и safety: вместе они дают более половины суммарной важности. Это согласуется с логикой набора данных: автомобиль, рассчитанный на 2 человека, или с низкой оценкой безопасности сразу относится к классу unacc, поэтому именно по этим признакам выполняются первые разбиения. Далее по значимости идут maint и lug_boot, наименее значимы buying и doors: цена покупки и число дверей слабо влияют на итоговую оценку.

5.4. Выбор алгоритма для данной задачи

Для оценки автомобиля по набору категориальных признаков при требовании максимальной точности предпочтительны градиентный бустинг (CatBoost или XGBoost): они дают наименьшее число ошибок и безошибочно определяют редкие классы. Если важны скорость и возможность объяснить решение, достаточно одиночного дерева решений, поскольку его accuracy (0.9827) лишь немного ниже.

Вывод: на практике сравнил работу одиночного дерева решений, случайного леса и бустинга для деревьев решений (AdaBoost, CatBoost, XGBoost) на наборе Car Evaluation. Лучшую точность показали CatBoost (accuracy 0.9923) и XGBoost (0.9904),

одиночное дерево и случайный лес дали по 0.9827, AdaBoost оказался наименее точным (0.9692). Наиболее важными признаками по оценке дерева решений являются persons и safety.