

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

По дисциплине «Интеллектуальный анализ данных»

Тема: «РСА»

Выполнил:

Студент 4 курса

Группы ИИ-25

Елец Ю. А.

Проверил:

Андренко К. В.

Цель работы: научиться применять метод PCA для осуществления визуализации данных.


Вариант 4



№ варианта	Выборка	Класс
4	heart+failure+clinical+records.zip	death_event

Задание:

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;

Результат:





Ручной PCA:

Объяснённая дисперсия (2 компоненты): 0.2702

Потери (2 компоненты): 0.7298

Объяснённая дисперсия (3 компоненты): 0.3759

Потери (3 компоненты): 0.6241

PCA sklearn:

Объяснённая дисперсия (2 компоненты): 0.2702

Потери информации (2 компоненты): 0.7298

Объяснённая дисперсия (3 компоненты): 0.3759

Потери информации (3 компоненты): 0.6241

Обе реализации PCA показали одинаковые значения объяснённой дисперсии и потерь, что говорит о правильности ручного алгоритма. Две компоненты сохраняют около 27 %

информации, потери составляют примерно 73 %, а три компоненты – 37 % информации и примерно 63 % потерь. Такие высокие потери говорят о том, что признаки в датасете слабо связаны между собой, а дисперсия распределена по многим направлениям, поэтому метод PCA плохо подходит для сжатия данных и их визуализации.

Вывод: в данной лабораторной работе я научилась применять метод PCA для осуществления визуализации данных.