Министерство образования Республики Беларусь

Учреждение образования

«Брестский Государственный технический университет»

Кафедра ИИТ

Лабораторная работа №5

По дисциплине «Интеллектуальный анализ данных»

Тема: «Деревья решений»

Выполнил:

Студент 4 курса

Группы ИИ-25

Елец Ю. А.

Проверил:

Андренко К. В.

Брест 2026

Цель работы: на практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Вариант 4

Задание:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 4

- Digits
- Распознать, какая цифра (от 0 до 9) изображена на картинке 8x8 пикселей
- **Задания:**
  1. Загрузите встроенный в scikit-learn набор данных digits;
  2. Разделите данные на обучающую и тестовую выборки;
  3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
  4. Для каждой модели выведите classification_report (sklearn.metrics), содержащий основные метрики для каждого класса;
  5. Сравните общую точность моделей и определите, какая из них лучше всего подходит для этой задачи.

Результат:

Данные: (1797, 64)
Количество классов: 10
Обучающая выборка: 1437
Тестовая выборка: 360

Дерево решений:

	precision	recall	f1-score	support
0	0.921	0.972	0.946	36
1	0.800	0.667	0.727	36
2	0.848	0.800	0.824	35
3	0.750	0.811	0.779	37
4	0.861	0.861	0.861	36
5	0.872	0.919	0.895	37
6	0.833	0.833	0.833	36
7	0.833	0.833	0.833	36
8	0.758	0.714	0.735	35
9	0.718	0.778	0.747	36
accuracy			0.819	360
macro avg	0.819	0.819	0.818	360
weighted avg	0.820	0.819	0.818	360

Случайный лес:

	precision	recall	f1-score	support
0	1.000	0.972	0.986	36
1	0.923	1.000	0.960	36
2	1.000	1.000	1.000	35
3	0.973	0.973	0.973	37
4	0.973	1.000	0.986	36
5	1.000	1.000	1.000	37
6	1.000	0.972	0.986	36
7	0.923	1.000	0.960	36
8	0.938	0.857	0.896	35
9	0.971	0.917	0.943	36
accuracy			0.969	360
macro avg	0.970	0.969	0.969	360
weighted avg	0.970	0.969	0.969	360

AdaBoost:

	precision	recall	f1-score	support
0	1.000	0.944	0.971	36
1	0.906	0.806	0.853	36
2	1.000	0.971	0.986	35
3	0.973	0.973	0.973	37
4	0.971	0.917	0.943	36
5	1.000	1.000	1.000	37
6	1.000	0.944	0.971	36
7	0.973	1.000	0.986	36
8	0.791	0.971	0.872	35
9	0.895	0.944	0.919	36
accuracy			0.947	360
macro avg	0.951	0.947	0.947	360
weighted avg	0.951	0.947	0.948	360

XGBoost:

	precision	recall	f1-score	support
0	1.000	0.972	0.986	36
1	0.914	0.889	0.901	36
2	1.000	1.000	1.000	35
3	0.949	1.000	0.974	37
4	0.973	1.000	0.986	36
5	1.000	1.000	1.000	37
6	1.000	0.972	0.986	36
7	0.973	1.000	0.986	36

8	0.939	0.886	0.912	35
9	0.973	1.000	0.986	36
accuracy			0.972	360
macro avg	0.972	0.972	0.972	360
weighted avg	0.972	0.972	0.972	360

CatBoost:

	precision	recall	f1-score	support
0	1.000	0.972	0.986	36
1	0.946	0.972	0.959	36
2	1.000	1.000	1.000	35
3	0.974	1.000	0.987	37
4	0.973	1.000	0.986	36
5	1.000	1.000	1.000	37
6	1.000	0.972	0.986	36
7	1.000	1.000	1.000	36
8	0.971	0.943	0.957	35
9	1.000	1.000	1.000	36
accuracy			0.986	360
macro avg	0.986	0.986	0.986	360
weighted avg	0.986	0.986	0.986	360

Сравнение точности:
CatBoost : 0.9861
XGBoost : 0.9722
Случайный лес : 0.9694
AdaBoost : 0.9472
Дерево решений : 0.8194

Среднее ± std accuracy по 10 разбиениям:
Дерево решений : 0.8325 ± 0.0188
Случайный лес : 0.9786 ± 0.0070
AdaBoost : 0.9542 ± 0.0085
XGBoost : 0.9750 ± 0.0081
CatBoost : 0.9800 ± 0.0081

Сравнение:

По результатам тестирования на тестовой выборке были получены следующие значения точности:

Модель	**Точность**
Дерево решений	0.8194
Случайный лес	0.9694
AdaBoost	0.9472
CatBoost	0.9861

XGBoost	0.9722

Одиночное дерево решений показало худший результат. Оно правильно распознало только 82% цифр, что ниже всех остальных моделей. Разброс по 10 разбиениям у него наибольший (±0.0188). Причина в том, что одно дерево строит грубые пороговые правила и не улавливает тонких различий между визуально похожими цифрами. Остальные модели значительно превзошли одиночное дерево: случайный лес – 0.9694, AdaBoost – 0.9472, XGBoost – 0.9722, CatBoost – 0.9861. Это объясняется тем, что ансамбли объединяют ответы многих деревьев, и ошибки одних компенсируются правильными решениями других.

Лучший результат показал CatBoost, его точность составила 0.9861. Случайный лес и XGBoost отстают незначительно, разница между ними и CatBoost лежит в пределах стандартного отклонения. Это означает, что модели практически равноценны по точности.

Для задачи распознавания рукописных цифр лучше всего подходят ансамблевые методы, а не одиночное дерево. Наибольшую точность обеспечивает CatBoost (0.9861), также высокие результаты показал XGBoost (0.9722), но он немного уступает CatBoost. При требовании простоты и отсутствия необходимости тонкой настройки оптимален случайный лес, дающий сопоставимый результат. Одиночное дерево решений (0.8194) для этой задачи не подходит, так как его точности недостаточно для надёжного распознавания.

Вывод: в данной лабораторной работе я сравнила работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.