

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей с использованием автоэнкодерного подхода»

Выполнил:

Студент 4 курса

Группы ИИ-25

Заседатель Н.С.

Проверила:

Андренко К.В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.

Задание:

1. Взять за основу любую сверточную или полносвязную архитектуру с количеством слоев более 3. Осуществить ее обучение (без предобучения) в соответствии с вариантом задания. Получить оценку эффективности модели, используя метрики, специфичные для решаемой задачи (например, MAPE – для регрессионной задачи или F1/Confusion matrix для классификационной).
2. Выполнить обучение с предобучением, используя автоэнкодерный подход, алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев с использованием автоэнкодера выбрать самостоятельно.
3. Сравнить результаты, полученные при обучении с/без предобучения, сделать выводы.
4. Выполните пункты 1 - 3 для датасетов из ЛР 2.
5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 6

№	Выборка	Тип задачи	Целевая переменная
6	https://archive.ics.uci.edu/dataset/265/physicochemical+properties+of+protein+tertiary+structure	регрессия	RMSD

Ход работы:

1. Обучение полносвязной нейронной сети без предобучения

Для выполнения задания в качестве основной модели была выбрана полносвязная нейронная сеть, содержащая четыре линейных слоя, что соответствует требованию о количестве слоёв более трёх. В качестве первого набора данных использовался CASP, предназначенный для решения задачи регрессии. Набор содержит 45730 объектов и 9 входных признаков. Целевой переменной является значение RMSD. Для CASP использовалась следующая архитектура сети: 9 – 32 – 16 – 8 – 1. Между скрытыми слоями использовалась функция активации ReLU, а выходной слой не содержит функции активации, поскольку решается задача регрессии. Данные были разделены на обучающую и тестовую выборки в соотношении 80/20, после чего входные признаки были стандартизированы с помощью StandardScaler. На первом этапе сеть обучалась обычным методом обратного распространения ошибки без предварительного обучения. Для оптимизации использовался алгоритм Adam, количество эпох обучения составило 100, размер батча – 128, скорость обучения – 0.001. Для оценки качества регрессионной модели использовались MAE, RMSE, R^2 и MAPE. MAPE для CASP рассчитывалась только для объектов с ненулевым значением RMSD, поскольку при нулевом истинном значении данная метрика становится неопределённой.

Получены следующие результаты:

MAE	RMSE	R^2	MAPE(RMSD > 0)
3.3561	4.3708	0.4923	81.90%

Таким образом, на первом этапе была получена базовая модель, результаты которой используются для последующего сравнения с сетью, прошедшей автоэнкодерное предобучение.

2. Обучение полносвязной нейронной сети с предобучением

На втором этапе для той же архитектуры было выполнено послойное предобучение с использованием автоэнкодеров. Такой подход позволяет сначала обучить отдельные скрытые слои сети на восстановление входных данных, а затем использовать полученные веса для инициализации основной нейронной сети. Для первого слоя основной сети создавался автоэнкодер: 9 – 32 – 9. После его обучения веса кодирующей части использовались для первого слоя основной сети. Затем данные преобразовывались с помощью обученного энкодера и использовались для обучения следующего автоэнкодера: 32 – 16 – 32. Аналогично выполнялось предобучение третьего слоя: 16 – 8 – 16. Таким образом, были последовательно получены веса для трёх скрытых слоёв основной сети 9 – 32 – 16 – 8 – 1. В автоэнкодерах использовалась функция активации ReLU в энкодере, а для оценки качества восстановления применялась среднеквадратичная ошибка MSE. Для обучения каждого автоэнкодера было выбрано 50 эпох. После получения предобученных весов выполнялись следующие этапы. Сначала веса скрытых слоёв переносились в основную сеть и фиксировались, после чего отдельно обучался последний выходной слой в течение 20 эпох. Затем все слои размораживались и выполнялось полное дообучение сети ещё в течение 100 эпох.

Условие останова. Для отдельных автоэнкодеров выбрано фиксированное число эпох: 50 на слой. Решение принято самостоятельно; в лекции указано, что обычно используется не более 100 эпох.

Получены следующие результаты:

MAE	RMSE	R ²	MAPE(RMSD > 0)
3.3423	4.3081	0.5068	87.48%

Полученные значения позволяют сравнить эффективность обычного обучения и обучения с предварительным автоэнкодерным предобучением.

3. Сравнение и выводы

Сравнение результатов обучения без предобучения и с использованием автоэнкодерного предобучения показывает, что для набора CASP предобучение немного улучшило основные показатели качества регрессии.

Метрика	Без предобучения	С предобучением	Изменение
MAE	3.3561	3.3423	-0.0138
RMSE	4.3708	4.3081	-0.0627
R ²	0.4923	0.5068	+0.0145
MAPE(RMSD > 0), %	81.90	87.48	+5.58

Выводы.

1. По MAE, RMSE и R² предобученная сеть показала незначительно лучший результат (MAE снизилась примерно на 0.4 %, RMSE – на 1.4 %). Разница мала.
2. По MAPE результат ухудшился. Эта метрика вычисляется относительно каждого истинного значения и сильно завышается на объектах с малым RMSD, где даже

небольшая абсолютная ошибка даёт большой процент. Поэтому MAPE здесь малоинформативна, и для оценки качества опираемся на MAE, RMSE и R^2 .

3. Абсолютное качество моделей умеренное: $R^2 \approx 0.5$, то есть сеть объясняет около половины дисперсии RMSD. Датасет CASP сложный: всего 9 признаков и шумная нелинейная зависимость.
4. Одной из возможных причин малого эффекта предобучения является большой объём обучающей выборки (36 584 объекта): согласно лекции, предобучение особенно полезно на малых выборках, а при большом объёме обычного метода обратного распространения ошибки с ReLU может быть достаточно.
5. Суммарный объём обучения у предобученной сети больше (50 эпох на каждый автоэнкодер и 20 эпох на выходной слой, помимо 100 эпох дообучения).

4. Выполнение пунктов 1 – 3 для датасета из ЛР 2 (WDBC)

В соответствии с заданием пункты 1 – 3 были повторены для датасета WDBC, который использовался в лабораторной работе №2. В отличие от CASP, здесь решается задача бинарной классификации. Набор WDBC содержит 569 объектов и 30 числовых признаков. Целевая переменная содержит два класса: доброкачественный и злокачественный диагноз. В программе классы были представлены числовыми значениями 0 и 1. Для классификации использовалась полносвязная сеть с архитектурой: 30 – 32 – 16 – 8 – 2. Последний слой содержит два выходных нейрона – по одному для каждого класса. Между скрытыми слоями используется ReLU. Для обучения классификатора применяется функция потерь CrossEntropyLoss. Данные разделялись на обучающую и тестовую выборки в соотношении 80/20 с использованием стратификации, чтобы сохранить соотношение классов. Входные признаки также стандартизировались с помощью StandardScaler

4.1. Обучение без предобучения

Сначала сеть обучалась обычным методом обратного распространения ошибки без предварительного обучения.

Получены следующие результаты:

F1	Accuracy	Матрица ошибок
0.9630	0.9737	[[72, 0], [3, 39]]

Матрица показывает, что из 72 объектов первого класса все были классифицированы правильно. Для второго класса 39 объектов были определены правильно, а 3 объекта были классифицированы неправильно.

4.2. Обучение с предобучением

Затем для WDBC была выполнена аналогичная процедура послойного автоэнкодерного предобучения. Последовательно обучались автоэнкодеры: 30 – 32 – 30; 32 – 16 – 32; 16 – 8 – 16. Для каждого автоэнкодера использовалась функция потерь MSE, а обучение выполнялось в течение 50 эпох. Полученные веса энкодеров переносились в соответствующие слои основной сети 30 – 32 – 16 – 8 – 2. После этого последний слой обучался отдельно при замороженных предобученных слоях в течение 20 эпох. Затем выполнялось дообучение всей сети в течение 100 эпох.

Получены следующие результаты:

F1	Accuracy	Матрица ошибок
0.9756	0.9825	[[72, 0], [2, 40]]

4.3. Сравнение и выводы

Метрика	Без предобучения	С предобучением	Изменение
F1	0.9630	0.9756	+0.0126
Accuracy	0.9737	0.9825	+0.0088
Ложноотрицательные (FN)	3	2	-1
Ложноположительные (FP)	0	0	0

Выводы.

1. Предобучение слегка улучшило результат: число пропущенных злокачественных опухолей снизилось с 3 до 2, F1 выросла с 0.963 до 0.976. Число ложных тревог осталось нулевым.
2. Разница составляет один объект из 114 тестовых. Из одного запуска нельзя сделать вывод, что улучшение устойчиво.
3. Направление эффекта согласуется с лекционным материалом: предобучение потенциально полезнее на малых выборках, а WDBC содержит всего 455 обучающих объектов.

5. Результат работы программы

Устройство: cpu	WDBC: классификация
	Размер: (569, 30)
CASP: регрессия	Архитектура: 30-32-16-8-2
Размер: (45730, 9)	
Архитектура: 9-32-16-8-1	Без предобучения:
	F1: 0.963
Без предобучения:	Accuracy: 0.9737
MAE: 3.3561	Матрица ошибок:
RMSE: 4.3708	[[72 0]
R2: 0.4923	[3 39]]
MAPE без нулей: 81.9 %	
	С предобучением:
С предобучением:	F1: 0.9756
MAE: 3.3423	Accuracy: 0.9825
RMSE: 4.3081	Матрица ошибок:
R2: 0.5068	[[72 0]
MAPE без нулей: 87.48 %	[2 40]]

Вывод: научился осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.