

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине: «Интеллектуальный анализ данных»
Тема: «Предобучение нейронных сетей с использованием RBM»

Выполнил:
Студент 4 курса
Группы ИИ-25
Заседатель Н.С.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью RBM.

Задание:

1. Взять за основу нейронную сеть из лабораторной работы №3. Выполнить обучение с предобучением, используя стек ограниченных машин Больцмана (RBM – Restricted Boltzmann Machine), алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев как RBM выбрать самостоятельно.
2. Сравнить результаты, полученные при
 - обучении без предобучения (ЛР 3);
 - обучении с предобучением, используя автоэнкодерный подход (ЛР3);
 - обучении с предобучением, используя RBM.
3. Обучить модели на данных из ЛР 2, сравнить результаты по схеме из пункта 2;
4. Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 6

№	Выборка	Тип задачи	Целевая переменная
6	https://archive.ics.uci.edu/dataset/265/physicochemical+properties+of+protein+tertiary+structure	регрессия	RMSD

Ход работы:

0. Общие особенности

- фреймворк: PyTorch, устройство: CPU. Генератор случайных чисел: seed = 42;
- оптимизатор для основной сети: Adam, скорость обучения 0.001, размер мини-батча 128, мини-батчи перемешиваются каждую эпоху. Активация скрытых слоёв: ReLU;
- данные: разбиение 80/20 (random_state = 42), для WDBC со стратификацией по классам. Признаки стандартизируются (StandardScaler), параметры вычисляются только по обучающей выборке;
- для всех трёх вариантов (без предобучения, AE, RBM) используются одинаковые архитектура, оптимизатор, разбиение данных и процедура дообучения;
- все результаты получены в одном запуске.

1. Предобучение стеком RBM

1.1. Архитектура

Взята полносвязная сеть из ЛР 3 (4 линейных слоя):

CASP: 9 – 32 – 16 – 8 – 1 (регрессия);

WDBC: 30 – 32 – 16 – 8 – 2 (классификация).

1.2. Алгоритм предобучения

Использован послойный алгоритм (greedy layer-wise) на основе RBM, приведённый в лекции:

1. Первая RBM n – 32 обучается на обучающих данных.
2. Скрытые вероятности $P(y=1|x)$ обученной RBM подаются на вход второй RBM 32 – 16, затем третьей 16 – 8.

3. Веса RBM переносятся в основную сеть: матрица W^T в веса слоя Linear, пороги скрытых нейронов T_j в смещения. Выходной слой остаётся со случайной инициализацией.
4. Обучение выходного слоя с учителем. Предобученные слои заморожены, обучается только последний слой (20 эпох; MSE для регрессии, CrossEntropy для классификации).
5. Дообучение всей сети алгоритмом обратного распространения ошибки (100 эпох).

1.3. Обучение одной RBM (contrastive divergence, CD-1)

Для каждого мини-батча выполняется:

Вычислить $P(y^{(0)}=1|x^{(0)}) = \text{sigm}(\sum_i w_{ij} x_i^{(0)} + T_j)$ и сгенерировать $y^{(0)} \in \{0, 1\}$ из этого распределения.

Вычислить реконструкцию видимого слоя $x^{(1)}$ по $y^{(0)}$.

Вычислить $P(y^{(1)}=1|x^{(1)}) = \text{sigm}(\sum_i w_{ij} x_i^{(1)} + T_j)$.

Обновить параметры:

- $W \leftarrow W + \alpha (x^{(0)} y^{(0)T} - x^{(1)} P(y^{(1)}=1|x^{(1)})^T)$
- $T_i \leftarrow T_i + \alpha (x^{(0)} - x^{(1)})$
- $T_j \leftarrow T_j + \alpha (y^{(0)} - P(y^{(1)}=1|x^{(1)}))$

Скрытые нейроны бинарные (сигмоида, с выборкой). Видимые нейроны первой RBM линейные (гауссовы), так как стандартизованные входы не лежат в $[0, 1]$; для второй и третьей RBM видимые нейроны сигмоидные с выборкой, поскольку их входы являются вероятностями из $[0, 1]$.

1.4. Параметры и условие останова

Параметр	Значение
Условие останова обучения каждой RBM	фиксированное число эпох: 50
Скорость обучения α	0.01
Момент	0.5 (первые 5 эпох), затем 0.9
Размер батча	128
Инициализация	$W \sim N(0, 0.01^2)$, пороги нулевые

Число эпох выбрано самостоятельно. Момент взят по реализации из лекции.

1.5. Ошибка реконструкции (средний квадрат ошибки, последняя эпоха)

Слой	CASP	WDBC
1-я RBM (n – 32)	0.3445	0.3572
2-я RBM (32 – 16)	0.0114	0.0542
3-я RBM (16 – 8)	0.0072	0.0532

Ошибки ненулевые и небольшие. Для первой RBM ошибка 0.34 – 0.36 относительно единичной дисперсии стандартизованных входов.

2. Сравнение на CASP (регрессия)

Данные.

45 730 объектов, 9 признаков, целевая переменная RMSD. Обучающая выборка 36 584 объекта, тестовая 9 146.

Метрики.

MAE, RMSE, R^2 , MAPE. MAPE вычисляется только для $RMSD > 0$ (при $RMSD = 0$ она не определена) и чувствительна к малым значениям цели.

Метод	MAE	RMSE	R ²	MAPE (RMSD > 0), %
Без предобучения	3.3561	4.3708	0.4923	81.90
Предобучение AE	3.3423	4.3081	0.5068	87.48
Предобучение RBM	3.4790	4.4925	0.4637	87.70

Изменение относительно обучения без предобучения:

Метод	MAE	RMSE	R ²
AE	−0.4 %	−1.4 %	+0.0145
RBM	+3.7 %	+2.8 %	−0.0286

Выводы.

- лучшие значения MAE, RMSE и R² у автоэнкодерного предобучения, но выигрыш над сетью без предобучения мал;
- предобучение RBM показало худшие значения по MAE, RMSE и R²;
- MAPE во всех случаях 80 – 88 % и как показатель качества малоинформативна: она завышается объектами с малым RMSD, поэтому основными метриками считаем MAE, RMSE и R².

3. Сравнение на WDBC

Данные. 569 объектов, 30 числовых признаков, 2 класса (В – доброкачественная, 357; М – злокачественная, 212; М кодируется как 1). Обучающая выборка 455 объектов, тестовая 114 (72 В и 42 М).

Метрики. F1 для положительного класса (М), Ассигасу, матрица ошибок.

Метод	F1	Ассигасу	Матрица ошибок	FP	FN
Без предобучения	0.9880	0.9912	[[72, 0], [1, 41]]	0	1
Предобучение AE	0.9512	0.9649	[[71, 1], [3, 39]]	1	3
Предобучение RBM	0.9756	0.9825	[[72, 0], [2, 40]]	0	2

Выводы.

- лучший результат у сети без предобучения (одна ошибка на 114 объектов), затем RBM (две ошибки), затем AE (четыре ошибки);
- различия составляют 1 – 3 объекта тестовой выборки;
- результаты базовой сети и AE на WDBC отличаются от приведённых в ЛР 3 (там F1 0.963 и 0.9756), хотя алгоритмы не менялись: изменилось состояние генератора случайных чисел, так как в одном запуске добавилось обучение RBM. Это показывает, что при таком размере тестовой выборки порядок моделей зависит от случайной инициализации.

4. Выводы

1. Реализация. Предобучение стеклом RBM реализовано по алгоритму из лекции: послойное обучение RBM по схеме CD-1 с моментом, перенос весов в сеть из ЛР 3, обучение выходного слоя с учителем, дообучение всей сети. Сравнение трёх способов выполнено на CASP и на WDBC.
2. CASP. Предобучение RBM не улучшило качество: MAE выросла с 3.356 до 3.479, RMSE с 4.371 до 4.493, R² снизился с 0.492 до 0.464. Автоэнкодерное предобучение немного лучше (MAE 3.342), но его отличие от обучения без предобучения мало.

3. WDBC. Наилучшие значения у сети без предобучения ($F1 = 0.988$), затем RBM (0.976) и AE (0.951). Различия составляют 1 – 3 объекта из 114 тестовых, а порядок моделей отличается от ЛР 3, поэтому в рамках одного запуска они не позволяют утверждать превосходство какого-либо способа.
4. Возможные причины:
 - большой объём обучающей выборки CASP, при котором обучения методом обратного распространения с ReLU достаточно (по лекции предобучение особенно полезно на малых выборках);
 - веса RBM получены для сигмоидных нейронов, а в основной сети используется ReLU;
 - малая размерность входа CASP (9 признаков) и небольшие размеры слоёв;
 - малый размер тестовой выборки WDBC.
5. Общий итог. На исследованных данных предобучение (AE и RBM) не дало подтверждённого преимущества над обычным обучением. На CASP предобучение RBM уступило обучению без предобучения; на WDBC различия между способами составляют 1 – 3 объекта тестовой выборки и находятся в пределах случайных колебаний.

5. Результат работы программы:

Устройство: cpi

CASP: регрессия

Размер: (45730, 9)

Архитектура: 9-32-16-8-1

Предобучение RBM:

RBM 9-32: ошибка реконструкции = 0.3445

RBM 32-16: ошибка реконструкции = 0.0114

RBM 16-8: ошибка реконструкции = 0.0072

Без предобучения:

MAE: 3.3561

RMSE: 4.3708

R2: 0.4923

MAPE (RMSD > 0): 81.9 %

AE:

MAE: 3.3423

RMSE: 4.3081

R2: 0.5068

MAPE (RMSD > 0): 87.48 %

RBM:

MAE: 3.479

RMSE: 4.4925

R2: 0.4637

MAPE (RMSD > 0): 87.7 %

WDBC: классификация

Размер: (569, 30)

Архитектура: 30-32-16-8-2

Предобучение RBM:

RBM 30-32: ошибка реконструкции = 0.3572

RBM 32-16: ошибка реконструкции = 0.0542

RBM 16-8: ошибка реконструкции = 0.0532

Без предобучения:

F1: 0.988

Accuracy: 0.9912

Матрица ошибок:

[[72 0]

[1 41]]

AE:

F1: 0.9512

Accuracy: 0.9649

Матрица ошибок:

[[71 1]

[3 39]]

RBM:

F1: 0.9756

Accuracy: 0.9825

Матрица ошибок:

[[72 0]

[2 40]]

Вывод: научился осуществлять предобучение нейронных сетей с помощью RBM.